

Minería de Datos

Tarea 2:

Regresión logística, selección automática de variables, PCA y clustering

Profesor: Alex Di Genova

15/06/2026

Información general

Fecha de Entrega:	06/07/2026
Modalidad:	Grupal, 2 a 3 integrantes
Formato:	Informe en PDF generado desde RMarkdown
Archivos requeridos:	Informe en PDF + archivo .Rmd
Entrega:	vía ucampus

Objetivo general

El objetivo de esta tarea es aplicar técnicas de minería de datos supervisadas y no supervisadas para resolver problemas de interpretación, reducción de dimensionalidad, selección de variables, clustering y predicción.

Requisitos generales

Cada grupo debe entregar un informe reproducible que incluya:

1. Carga, limpieza y descripción de los datos.
2. Visualizaciones relevantes con `ggplot2`.
3. Modelos correctamente ajustados y comparados.
4. Interpretación estadística y conceptual de los resultados.
5. Discusión de limitaciones.
6. Código ordenado, comentado y reproducible.

Se sugiere usar los siguientes paquetes:

```
library(tidyverse)
library(tidymodels)
library(glmnet)
library(MASS)
library(broom)
library(pROC)
library(yardstick)
library(palmerpenguins)
library(titanic)
library(modeldata)
library(factoextra)
library(cluster)
library(ggrepel)
```

1. Problema 1: Predicción de supervivencia en Titanic

Dataset: `titanic::titanic_train`

Contexto

El dataset Titanic contiene información de los pasajeros del Titanic, incluyendo edad, sexo, clase del ticket, número de familiares a bordo, tarifa pagada y si sobrevivieron o no. El objetivo es construir modelos de regresión logística para predecir la supervivencia y comparar distintas estrategias de selección de variables.

La variable respuesta será:

`Survived`

donde:

- 0: no sobrevivió.
- 1: sobrevivió.

1.1. Exploración y limpieza de datos

- a) Cargue el dataset y describa sus dimensiones, tipos de variables y porcentaje de valores perdidos por columna.
- b) Limpie los datos considerando al menos las variables:

`Survived, Pclass, Sex, Age, SibSp, Parch, Fare, Embarked`

- c) Justifique cómo manejará los valores perdidos, especialmente en `Age` y `Embarked`.
- d) Transforme las variables categóricas en factores cuando corresponda.

1.2. Visualización exploratoria

Construya al menos cuatro visualizaciones con `ggplot2`, incluyendo:

- a) Supervivencia según sexo.
- b) Supervivencia según clase del pasajero.
- c) Distribución de edad según supervivencia.
- d) Relación entre tarifa pagada, `Fare`, y supervivencia.

Interprete cada gráfico en términos de patrones relevantes para la predicción.

1.3. Modelo logístico base

Ajuste un modelo de regresión logística usando como predictores:

`Pclass + Sex + Age + SibSp + Parch + Fare + Embarked`

Responda:

- a) ¿Qué variables son estadísticamente significativas?
- b) Interprete al menos cuatro coeficientes usando odds ratios.
- c) ¿Qué significa un odds ratio mayor que 1? ¿Y menor que 1?
- d) ¿Qué limitaciones tiene interpretar significancia estadística sin evaluar desempeño predictivo?

1.4. Selección automática por AIC

Aplique selección automática de variables usando AIC, por ejemplo mediante:

`MASS::stepAIC()`

Responda:

- a) ¿Qué variables fueron seleccionadas?
- b) ¿El modelo seleccionado por AIC es más simple que el modelo completo?

- c) Compare el AIC del modelo completo y del modelo seleccionado.
- d) Discuta si un menor AIC implica necesariamente mejor capacidad predictiva.

1.5. Ridge y lasso

Ajuste modelos de regresión logística regularizada usando `glmnet`:

- a) Ridge regression.
- b) Lasso regression.
- c) Seleccione `lambda` usando validación cruzada.
- d) Compare los valores de `lambda.min` y `lambda.1se`.
- e) Identifique qué variables conserva lasso en el modelo final.

1.6. Evaluación predictiva

Divida los datos en entrenamiento y prueba, por ejemplo 70/30.

Compare los siguientes modelos:

1. Regresión logística completa.
2. Regresión logística seleccionada por AIC.
3. Ridge.
4. Lasso.

Use al menos las siguientes métricas:

- Accuracy.
- Sensibilidad.
- Especificidad.
- AUC ROC.
- Matriz de confusión.

Responda:

- a) ¿Cuál modelo tiene mejor desempeño predictivo?
- b) ¿Cuál modelo es más interpretable?
- c) ¿Existe una diferencia importante entre el modelo más interpretable y el más predictivo?
- d) ¿Qué modelo recomendaría y por qué?

2. Problema 2: PCA y clustering en pingüinos

Dataset: `palmerpenguins::penguins`

Contexto

El dataset `penguins` contiene mediciones morfológicas de pingüinos de distintas especies e islas. En este problema se aplicará PCA para reducir la dimensionalidad y clustering para identificar grupos naturales sin usar inicialmente la variable `species`.

Variables sugeridas:

```
bill_length_mm
bill_depth_mm
flipper_length_mm
body_mass_g
```

Variables de comparación posterior:

```
species
island
sex
```

2.1. Preparación de datos

- Cargue el dataset y describa sus variables.
- Seleccione las variables morfológicas numéricas.
- Elimine o impute valores perdidos. Justifique su decisión.
- Estandarice las variables antes de aplicar PCA y clustering.

Explique por qué es necesario escalar las variables en este caso.

2.2. Visualización exploratoria

Construya visualizaciones con `ggplot2` para explorar:

- Distribución de la masa corporal por especie.
- Relación entre la longitud y la profundidad del pico.
- Relación entre el largo de aleta y la masa corporal.
- Diferencias morfológicas por isla.

Interprete los patrones observados.

2.3. PCA

Aplice PCA usando las variables numéricas estandarizadas.

Responda:

- ¿Qué porcentaje de varianza explica PC1?
- ¿Qué porcentaje de varianza explica PC2?
- ¿Cuántos componentes se necesitan para explicar al menos 80 % de la varianza?
- Interprete las cargas de PC1 y PC2.
- ¿Qué variables contribuyen más a cada componente?

Construya:

- Scree plot.
- Gráfico PC1 vs PC2 coloreado por especie.
- Biplot o gráfico de cargas.

2.4. Interpretación biológica y estadística del PCA

Responda:

- ¿PC1 parece representar el tamaño corporal en general? Justifique usando las cargas.
- ¿PC2 parece separar la forma del pico u otra característica morfológica?
- ¿Las especies se separan claramente en el espacio del PCA?
- ¿Qué especies se solapan más?
- ¿Qué ventajas ofrece PCA para visualizar este dataset?

2.5. Clustering con k-means

Aplice k-means usando las variables numéricas estandarizadas.

Debe probar al menos:

$k = 2, 3, 4, 5$

Responda:

- Use el método del codo y silhouette para elegir un número razonable de clusters.
- Ajuste el modelo final de k-means.
- Visualice los clústeres en el espacio PC1-PC2.
- Compare los clústeres obtenidos con la variable real `species`.

- e) Construya una tabla cruzada entre clúster y especie.
- f) Discuta si los clústeres recuperan las especies biológicas.

2.6. Clustering jerárquico

Aplice clustering jerárquico usando al menos dos métodos de enlace:

- Complete linkage.
- Ward.

Responda:

- a) Construya dendrogramas.
- b) Corte el dendrograma en el número de clústeres que considere apropiado.
- c) Compare los resultados con los de k-means.
- d) ¿Qué método entrega grupos más coherentes con las especies?

2.7. Discusión avanzada

Responda:

- a) ¿Por qué el clustering no supervisado no debe evaluarse únicamente por su coincidencia con las especies?
- b) ¿Qué otros patrones podría estar captando el clustering?
- c) ¿Qué diferencia hay entre usar PCA para visualización y usar PCA como entrada para clustering?
- d) ¿Qué riesgos existen al interpretar los clusters como categorías reales?

3. Problema 3: Predicción de rotación laboral con selección de variables, PCA y clustering

Dataset: `modeldata::attrition`

Contexto

El dataset `attrition` contiene información sobre trabajadores de una empresa, incluyendo variables demográficas, laborales, salariales, de satisfacción, de antigüedad, de horas extra, de cargo y si la persona dejó o no la organización.

El objetivo es construir modelos predictivos para clasificar la rotación laboral y, al mismo tiempo, interpretar qué factores se asocian con una mayor probabilidad de abandono laboral.

Cargue los datos usando:

```
data(attrition, package = "modeldata")
```

La variable respuesta será:

```
Attrition
```

donde usualmente toma los valores:

- **Yes:** el trabajador dejó la empresa.
- **No:** el trabajador permaneció en la empresa.

3.1. Preparación de datos

- a) Cargue el dataset `attrition`.
- b) Explore las dimensiones del dataset, los tipos de variables y la presencia de valores perdidos.
- c) Revise la distribución de la variable de respuesta `Attrition`.
- d) Discuta si existe un desbalance de clases. ¿Qué consecuencias podría tener para la predicción?
- e) Separe los datos en entrenamiento y prueba usando una partición 70/30 o 80/20.
- f) Identifique variables numéricas y categóricas.
- g) Diseñe una estrategia de preprocesamiento que incluya:

- Conversión de variables categóricas a factores.
- Creación de variables dummy.
- Estandarización de variables numéricas.
- Eliminación de variables con varianza cero o casi cero.
- Tratamiento de posibles valores perdidos, si existieran.

Explique brevemente por qué es necesario cada paso.

3.2. Visualización exploratoria

Construya al menos cinco visualizaciones con `ggplot2`, incluyendo:

- a) Proporción de rotación laboral según `OverTime`.
- b) Distribución de `MonthlyIncome` según `Attrition`.
- c) Relación entre `Age` y `Attrition`.
- d) Proporción de rotación laboral según `JobRole`.
- e) Relación entre `YearsAtCompany` y `Attrition`.

Además, construya una visualización adicional, a elección del grupo, que permita explorar una hipótesis relevante.

Interprete los gráficos respondiendo:

- a) ¿Qué variables parecen asociarse con una rotación más alta?
- b) ¿Qué patrones podrían ser útiles para un modelo predictivo?
- c) ¿Hay variables que parecen presentar una relación no lineal con la rotación?

3.3. Modelo logístico interpretable

Construya un modelo de regresión logística usando un subconjunto razonable de variables, por ejemplo:

```
Attrition ~ Age + MonthlyIncome + OverTime + JobSatisfaction +
  YearsAtCompany + DistanceFromHome + JobLevel + WorkLifeBalance +
  TotalWorkingYears + JobRole
```

Responda:

- a) ¿Qué variables se asocian con una mayor probabilidad de rotación laboral?
- b) Interprete al menos cinco coeficientes usando odds ratios.
- c) ¿Qué significa que el odds ratio de una variable sea mayor que 1?
- d) ¿Qué significa que el odds ratio de una variable sea menor que 1?
- e) ¿Qué variables podrían resultar más útiles para una intervención organizacional?

3.4. Selección automática por AIC

Aplice la selección automática de variables mediante el criterio AIC a un modelo logístico con múltiples predictores.

Puede usar, por ejemplo:

```
MASS::stepAIC()
```

Responda:

- a) ¿Qué variables fueron seleccionadas?
- b) ¿El modelo final es más simple que el modelo inicial?
- c) ¿Qué variables fueron eliminadas?
- d) ¿Coinciden las variables seleccionadas con las observadas en el análisis exploratorio?
- e) ¿Un menor AIC garantiza una mejor predicción en datos nuevos? Justifique.

3.5. Ridge y lasso

Usando una matriz de predictores con variables numéricas y variables dummy, ajuste modelos de regresión logística regularizada:

- a) Ridge logistic regression.
- b) Lasso logistic regression.
- c) Seleccione `lambda` usando validación cruzada.
- d) Compare `lambda.min` y `lambda.1se`.
- e) Identifique qué variables conserva lasso con coeficientes distintos de cero.
- f) Construya un gráfico con los coeficientes más relevantes del modelo lasso.
- g) Compare las variables seleccionadas por lasso con las seleccionadas por AIC.

Discuta:

- a) ¿Lasso selecciona un conjunto más pequeño de variables?
- b) ¿Ridge elimina variables?
- c) ¿Qué método parece más útil para interpretación?
- d) ¿Qué método parece más útil para predicción?

3.6. Evaluación predictiva

Compare los siguientes modelos en el conjunto de prueba:

1. Regresión logística interpretable.
2. Regresión logística seleccionada por AIC.
3. Ridge.
4. Lasso.

Use al menos las siguientes métricas:

- Accuracy.
- Sensibilidad.
- Especificidad.
- Balanced accuracy.
- AUC ROC.
- Matriz de confusión.

Responda:

- a) ¿Cuál modelo tiene mayor AUC?
- b) ¿Cuál modelo tiene mejor sensibilidad para detectar trabajadores que dejan la empresa?
- c) ¿Por qué accuracy podría ser una métrica engañosa si hay desbalance de clases?
- d) ¿Qué modelo recomendaría si el objetivo principal es detectar posibles casos de rotación?
- e) ¿Qué modelo recomendaría si el objetivo principal es explicar los factores asociados?

3.7. PCA aplicado a variables laborales numéricas

Seleccione solo variables numéricas del dataset, por ejemplo:

```
Age
DailyRate
DistanceFromHome
Education
EnvironmentSatisfaction
HourlyRate
JobInvolvement
JobLevel
JobSatisfaction
MonthlyIncome
MonthlyRate
NumCompaniesWorked
PercentSalaryHike
```

```
PerformanceRating
RelationshipSatisfaction
StockOptionLevel
TotalWorkingYears
TrainingTimesLastYear
WorkLifeBalance
YearsAtCompany
YearsInCurrentRole
YearsSinceLastPromotion
YearsWithCurrManager
```

Aplique PCA sobre estas variables estandarizadas.

Responda:

- ¿Cuánta varianza explica PC1?
- ¿Cuánta varianza explica PC2?
- ¿Cuántos componentes se necesitan para explicar al menos 80 % de la varianza?
- ¿Qué variables cargan más en PC1?
- ¿Qué variables cargan más en PC2?
- Interprete conceptualmente los dos primeros componentes principales.

Construya:

- Scree plot.
- Gráfico PC1 vs PC2 coloreado por `Attrition`.
- Gráfico de contribución de variables a PC1 y PC2.

3.8. Modelo usando componentes principales

Construya un modelo de regresión logística usando como predictores los primeros componentes principales que expliquen al menos 80 % de la varianza.

Compare este modelo con:

- Modelo logístico interpretable.
- Modelo seleccionado por AIC.
- Ridge.
- Lasso.

Use las mismas métricas de evaluación predictiva.

Responda:

- ¿El modelo basado en PCA mejora o empeora la predicción?
- ¿Qué se gana al aplicar PCA antes de la regresión logística?
- ¿Qué se pierde en términos de interpretación?
- ¿Recomendaría PCA para este problema? Justifique.

3.9. Clustering de perfiles laborales

Usando las variables numéricas estandarizadas o los primeros componentes principales, aplique técnicas de clustering para identificar perfiles de trabajadores.

Debe aplicar al menos:

- k-means.
- Clustering jerárquico.

Responda:

- Use método del codo y silhouette para proponer un número razonable de clusters.
- Ajuste un modelo k-means final.

- c) Visualice los clusters en el espacio PC1-PC2.
- d) Aplique clustering jerárquico usando al menos dos métodos de enlace, por ejemplo `complete` y `ward.D2`.
- e) Compare los clusters obtenidos con la variable `Attrition`.
- f) Caracterice cada cluster usando variables como edad, ingreso mensual, años en la empresa, satisfacción laboral y horas extra.
- g) ¿Algún clúster concentra una mayor proporción de trabajadores que abandonan la empresa?
- h) ¿Qué interpretación organizacional podrían tener los clústeres encontrados?

3.10. Discusión final del problema

Responda:

- a) ¿Qué variables parecen más importantes para predecir rotación laboral?
- b) ¿Qué modelo tuvo mejor desempeño predictivo?
- c) ¿Qué modelo fue más interpretable?
- d) ¿Qué aportó PCA al análisis?
- e) ¿Qué aportó clustering al análisis?
- f) ¿Qué limitaciones tiene este dataset para tomar decisiones reales en recursos humanos?
- g) ¿Qué precauciones éticas deberían considerarse antes de usar un modelo de predicción de rotación laboral en una organización?